Python para Ciência de Dados

NumPy, Matplotlib, Pandas Introdutório



Luiz Alberto

Ciência da Computação

May 25, 2019



Importação de Dados

- Arquivos flat (e.g., .txt ou csv)
- Arquivos de outros software (e.g, Excel ou Matlab)
- Banco de dados relacionais



Lendo arquivos textos

```
import pandas as pd
nome = 'ciencia-de-dados.txt'
arquivo = open(nome, mode='r') # modo de leitura
texto = arquivo.read()
arquivo.close()
```



Imprimindo arquivos textos

```
1 import pandas as pd
2 nome = 'ciencia-de-dados.txt'
3 arquivo = open(nome, mode='r') # modo de leitura
4 texto = arquivo.read()
5 arquivo.close()
6 print(texto)
8 # Data science is a multi-disciplinary field that uses
  # scientific methods, processes, algorithms and
10 # systems to extract knowledge and insights from structured
11 # and unstructured data. Data science is the same concept
12 # as data mining and big data: "use the most powerful
13 # hardware, the most powerful programming systems, and the
# most efficient algorithms to solve problems
```



Escrevendo em arquivos textos

```
1 import pandas as pd
2 nome = 'ciencia-de-dados.txt'
3 arquivo = open(nome, mode='a') # modo escrita no final.
4 arquivo.write("\nEND-OF-FILE")
5 arquivo.close()
6
  # Data science is a multi-disciplinary field that uses
8 # scientific methods, processes, algorithms and
  # systems to extract knowledge and insights from structured
10 # and unstructured data. Data science is the same concept
11 # as data mining and big data: "use the most powerful
12 # hardware, the most powerful programming systems, and the
# most efficient algorithms to solve problems
14 # # END-OF-FILE
```



Utilizando a cláusula with

```
import pandas as pd
nome = 'ciencia-de-dados.txt'
with open(nome, mode='r') as file:
    print(file.read())

### Data science is a multi-disciplinary field that uses
### scientific methods, processes, algorithms and
### systems to extract knowledge and insights from structured
### and unstructured data. Data science is the same concept
### as data mining and big data: "use the most powerful
### hardware, the most powerful programming systems, and the
#### most efficient algorithms to solve problems"
#### END-OF-FILE
```



Lendo o arquivo texto linha a linha

```
import pandas as pd
nome = 'ciencia-de-dados.txt'
with open(nome, mode='r') as arquivo:
    print(arquivo.readline())
    print(arquivo.readline())

print(arquivo.readline())

# Data science is a multi-disciplinary field that uses ...

# systems to extract knowledge and insights from structured
    ...

# is the same concept as data mining and big data: ...
```




Hora de colocar as mãos na massa

- Clone o repositorio do curso na sua máquina.
 - git clone https://github.com/gomesluiz/python-para-ciencia-de-dados.git
- Na pasta python-para-ciencia-de-dados/notebooks, abra o arquivo aula-3-maos-na-massa-1.ipynb
- Faça todos os exercícios neste notebook.



Estrutura de arquivos flat





Cabeçalhos de flat

titanic.csv

```
PassengerId, Survived, Pclass, Name, Gender, Age, SibSp, Parch, Ticket, Fare, Cabin, Embarked 1,0,3, "Braund, Mr. Owen Harris", male, 22,1,0,A/5 21171,7.25,,S 2,1,1, "Cumings, Mrs. John Bradley (Florence Briggs Thayer)", female, 38,1,0,PC 17599,71.2833,C85,C 3,1,3," Heikkinen, Miss. Laina", female, 26,0,0,STON/O2. 3101282,7.925,,S 4,1,1,"Futrelle, Mrs. Jacques Heath (Lily May Peel)", female, 35,1,0,113803,53.1,C123,S 5,0,3,"Allen, Mr. William Henry", male,35,0,0,373450,8.05,,S 6,0,3,"Moran, Mr. James", male,,0,0,330877,8.4583,,Q 7,0,1,"McCarthy, Mr. Timothy J", male,54,0,0,17463,51.8625,E46,S 8,0,3,"Palsson, Master. Gosta Leonard", male,2,3,1,349909,21.075,,S 9,1,3,"Johnson, Mrs. Oscar W (Elisabeth Vilhelmina Berg)", female, 27,0,2,347742,11.1333,,S
```




Tipos de arquivos flat

- .csv Comma Separated Values
- .txt Text file
- Tab-delimited file



Tab-Delimited File





Importando Arquivos com NumPy

- NumPy arrays: estrutura otimizada para dados numéricos
- Essencial para outros pacotes: e.g. scikit-learn

```
import numpy as np
arquivo = 'MNIST.TXT'

dados = np.loadtxt(arquivo, delimiter=',')

print(dados)

#[[7. 0. 0. ... 0. 0. 0.]

# [2. 0. 0. ... 0. 0. 0.]

# [1. 0. 0. ... 0. 0. 0.]

# [9. 0. 0. ... 0. 0. 0.]

# [9. 0. 0. ... 0. 0. 0.]

# [9. 0. 0. ... 0. 0. 0.]
```



Hora de colocar as mãos na massa

- Na pasta python-para-ciencia-de-dados/notebooks, abra o arquivo aula-3-maos-na-massa-2.ipynb
- Faça todos os exercícios neste notebook.



Importação de arquivos com Pandas

- Estrutura bidimensionais com nomes de colunas
- Colunas com tipos diferentes de dados
- Manipulação, fatiamento, agrupamento e etc
- Estatísticas
- Series temporais



Manipulação de datafranes com Pandas

- Análise de dados exploratória
- Limpeza de dados
- Pré-processamento de dados
- Construção de modelos
- Visualização de dados



Importando arquivos csv com Pandas

```
1 import pandas as pd
2 arquivo = "winequality-red.csv"
3 dados = pd.read_csv(arquivo, sep=';') # arquivo separado por ;
4 print(dados.head())
     fixed acidity volatile acidity citric acid
               7.4
                               0.70
                                         0.00
               7.8
                               0.88
                                        0.00
              7.8
                               0.76
                                         0.04
              11.2
                               0.28
                                        0.56
               7.4
                               0.70
                                         0.00
```



Hora de colocar as mãos na massa

- Na pasta python-para-ciencia-de-dados/notebooks, abra o arquivo aula-3-maos-na-massa-3.ipynb
- Faça todos os exercícios neste notebook.



Importando Arquivos do Excel com Pandas

```
import pandas as pd
arquivo = "condominio-balanca-mas-nao-cai.xlsx"
dados = pd.ExcelFile(arquivo)
print(dados.sheet_names)
# ['Jan19', 'Fev19', 'Mar19', 'Abr19']
df1 = dados.parse('Jan19')
df2 = dados.parse(0)
```



Hora de colocar as mãos na massa

- Na pasta python-para-ciencia-de-dados/notebooks, abra o arquivo aula-3-maos-na-massa-4.ipynb
- Faça todos os exercícios neste notebook.



Trabalhando com banco de dados relacionais (1)

- Baseados no modelo relacional, Edgar "Ted" Codd foi o primeiro a descrevê-lo
- Um banco de dados relacional é baseado entidades, denominadas tabelas, no relacionamento, associações, entre elas
- O contêiner fundamental em um banco de dados relacional é denominado de database ou schema
 - podem incluir estruturas de dados, os dados propriamente ditos e permissões de acesso



Trabalhando com banco de dados relacionais (2)

 Os dados são armazenados em tabelas e as tabelas são divididas em linhas e colunas. Por exemplo:

Table: comment

id	post_id	body
10	1	Python realmente
11	2	Python facilita
13	2	Concordo,

Relacionamentos são estabelecidos entre tabelas para que a consistência dos dados seja mantida em qualquer situação e podem ser:



Trabalhando com banco de dados relacionais (3)

□ 1:1, 1:N ou N:M

Table: comment

 id
 post_id
 body

 10
 1
 Python realmente...

 11
 2
 Pandas facilita...

 13
 2
 Concordo, ...

Table: post

id	title	body
1	A Ling. Python	Python é legal.
2	O Pandas	O Pandas



20th Ave.

Exemplo de banco de dados relacional

Orders table

Blauer See

Delikatessen

Hanna Moos

Laurence

Lebihan

OrderID	CustomerID	EmployeeID	OrderDate	RequiredDate	ShippedDate	ShipVia	Freight	ShipName	ShipAddress					
10248	VINET	5	7/4/1996 12:00:00 AM	8/1/1996 12:00:00 AM	7/16/1996 12:00:00 AM	3	32.38	Vins et alcools Chevalier	59 rue de l'Abbaye	,	•	Emp	loye	ees
10251	VICTE	3	7/8/1996 12:00:00 AM	8/5/1996 12:00:00 AM	7/15/1996 12:00:00 AM	1	41.34	Victuailles en stock	2, rue du Commerce		EmployeelD	LastName	FirstName	Title
			7/11/1996	0/0/1000	7/00/4000			Chan area						Sales

Forsterstr.

12. rue

Bouchers

Representative 57

Owner des Mannheim None

Employees table

TitleOfCourtesy BirthDate HireDate 12/8/1948 5/1/1992

	10254	CHOPS 5				12:00:00 AM	2		hinese	lauptstr. 31	ľ	ľ	Davollo	reancy	Representative	MIS.		AM	E.\r\nApt. 2A	Seattre	WA
•		Custo	ome	ers ta	able						2	,	Fuller	Andrew	Vice President, Sales	Dr.		8/14/1992 12:00:00 AM	908 W. Capital Way	Tacoma	WA
1	Custome	rID CompanyN	Name Con	ntactName	ContactTitle	Address	City	Region	PostalCod	e Country	_	\rightarrow									
	ALFKI	Alfreds Futterkiste	Mar		Sales Representative	Obere Str. 57	Berlin	None	12209	Germany	3	3 Lev	Leverling .	Janet	Sales Representative	Ms.		4/1/1992 12:00:00	722 Moss Bay Blvd.	Kirkland 1	WA
	AROUT	Around the	Tho				London	None	WA1 1DP	UK					nepresentative		AM	AM	Day bivu.		
ı		1.10				Sq.				1 1											

Germany

13008 France

BLAUS

BONAP Bon app'



Estrutura da tabela Orders

OrderID	CustomerID	EmployeeID	OrderDate	RequiredDate	ShippedDate	ShipVia	Freight	ShipName	ShipAddress
10248	VINET	5	7/4/1996 12:00:00 AM	8/1/1996 12:00:00 AM	7/16/1996 12:00:00 AM	3	32.38	Vins et alcools Chevalier	59 rue de l'Abbaye
10251	VICTE	3	7/8/1996 12:00:00 AM	8/5/1996 12:00:00 AM	7/15/1996 12:00:00 AM	1	41.34	Victuailles en stock	2, rue du Commerce
10254	CHOPS	5	7/11/1996 12:00:00 AM	8/8/1996 12:00:00 AM	7/23/1996 12:00:00 AM	2	22.98	Chop-suey Chinese	Hauptstr. 31



Relacionamento entre as tabelas

Orders table

OrderID	CustomerID	EmployeeID	OrderDate	RequiredDate	ShippedDate	ShipVia	Freight	ShipName	ShipAddress
10248	VINET	5	7/4/1996 12:00:00 AM	8/1/1996 12:00:00 AM	7/16/1996 12:00:00 AM	3	32.38	Vins et alcools Chevalier	59 rue de l'Abbaye
10251	VICTE	3	7/8/1996 12:00:00 AM	8/5/1996 12:00:00 AM	7/15/1996 12:00:00 AM	1	41.34	Victuailles en stock	2, rue du Commerce
10254	CHOPS	5	7/11/1996 12:00:00 AM	8/8/1996 12:00:00 AM	7/23/1996 12:00:00 AM	2	22.98	Chop-suey Chinese	Hauptstr. 31
							_		

Customers table

CustomerID	CompanyName	ContactName	ContactTitle	Address	City	Region	PostalCode	Country
ALFKI	Alfreds Futterkiste	Maria Anders	Sales Representative	Obere Str. 57	Berlin	None	12209	Germany
AROUT	Around the Horn	Thomas Hardy	Sales Representative	120 Hanover Sq.	London	None	WA1 1DP	UK
BLAUS	Blauer See Delikatessen	Hanna Moos	Sales Representative	Forsterstr. 57	Mannheim	None	68306	Germany
BONAP	Bon app'	Laurence Lebihan	Owner	12, rue des Bouchers	Marseille	None	13008	France

Employees table

EmployeeID	LastName	FirstName	Title	TitleOfCourtesy	BirthDate	HireDate	Address	City	Region
1	Davolio	Nancy	Sales Representative	Ms.	12/8/1948 12:00:00 AM	5/1/1992 12:00:00 AM	507 - 20th Ave. E.\r\nApt. 2A	Seattle	WA
2	Fuller	Andrew	Vice President, Sales	Dr.	2/19/1952 12:00:00 AM	8/14/1992 12:00:00 AM	908 W. Capital Way	Tacoma	WA
3	Leverling	Janet	Sales Representative	Ms.	8/30/1963 12:00:00 AM	4/1/1992 12:00:00 AM	722 Moss Bay Blvd.	Kirkland	WA



Sistemas Gerenciadores de Banco de Dados

- PostgreSQL
- MySQL
- SQLite
- Oracle
- MS SQL Server
- DB2
- IBM Informix
- SQL = Structured Query Language




Manipulando Banco de Dados em Python

Criando um vínculo com banco de dados com o pacote SQLAlchemy (https://www.sqlalchemy.org/)

```
from sqlalchemy import create_engine
engine = create_engine('sqlite:///Northwind.sqlite')
```

Descobrindo os nomes das tabelas do banco de dados

```
1 from sqlalchemy import create_engine
2 engine = create_engine('sqlite:///Northwind.sqlite')
3 tabelas = engine.table_names()
4 print(tabelas)
```



- Importar pacotes e funções
- Criar o vínculo do banco de dados (database engine)
- Connectar ao banco de dados
- Consultar o banco de dados
- Salvar a consulta em um dataframe
- Fechar a conexão.



Etapas para Consulta no Banco de Dados (2)

```
import pandas as pd
  from sqlalchemy import create_engine
  engine = create_engine('sqlite:///Northwind.sqlite',
    encoding='utf-16')
6
  con = engine.connect()
  rs = con.execute("SELECT * FROM Orders")
Q
  df = pd.DataFrame(rs.fetchall())
  df.columns = rs.keys()
13 con.close()
14
print(df.head())
```




Utilizando a cláusula with

```
import pandas as pd
from sqlalchemy import create_engine

engine = create_engine('sqlite:///Northwind.sqlite')

with engine.connect() as con:
    rs = con.execute("SELECT * FROM Orders")
    df = pd.DataFrame(rs.fetchmany(size=5))
    df.columns = rs.keys()

print(df.head())
```



```
import pandas as pd
from sqlalchemy import create_engine

engine = create_engine('sqlite:///Northwind.sqlite')

with engine.connect() as con:
    rs = con.execute("SELECT * FROM Orders WHERE Freight > 100.00")
    df = pd.DataFrame(rs.fetchmany(size=5))
    df.columns = rs.keys()

print(df.head())
```

Ordenando uma consulta com a cláusula **order** by

python

```
import pandas as pd
from sqlalchemy import create_engine

dengine = create_engine('sqlite:///Northwind.sqlite')

with engine.connect() as con:
    rs = con.execute("SELECT * FROM Orders ORDER BY OrderDate")
    df = pd.DataFrame(rs.fetchmany(size=5))
    df.columns = rs.keys()

print(df.head())
```



Relacionando mais de uma tabela

```
1 import pandas as pd
  from sqlalchemy import create_engine
  engine = create_engine('sqlite:///Northwind.sqlite')
5
  with engine.connect() as con:
    rs = con.execute(
      "SELECT OrderID, CompanyName FROM Orders" +
      " INNER JOIN Customer ON Orders.CustomerID = Customer.
      Customer ID"
10
    df = pd.DataFrame(rs.fetchmany(size=5))
11
    df.columns = rs.keys()
13
14 print (df.head())
```



Módulos do SQLAlchemy

- Core (Foco no modelo relacional)
- ORM (Foco no modelo orientado a objetos



Conectando ao banco de dados

```
import pandas as pd
from sqlalchemy import create_engine

engine = create_engine('sqlite:///census_nyc.sqlite')
conn = engine.connect()
```

- engine: uma interface comum entre o SQLAlchemy e o banco de dados
- string de conexão: todos os detalhes para localizar o banco de dados (e login, se necessário)



Utilizando o SQLAlchemy para consultas

- Fornece uma maneira "Pitônica" de construir consultas
- Esconde as diferenças entre diversos bancos de dados



Extraindo campos dos resultados

```
1 import pandas as pd
2 from sqlalchemy import create_engine, Table, MetaData, select
  engine = create_engine('sqlite:///Northwind.sqlite')
5 conn = engine.connect()
  metadata = MetaData()
8 pedidos = Table('Orders', metadata, autoload=True,
    autoload_with=engine)
#print(repr(pedidos))
12 comando = select([pedidos])
13 resultados = conn.execute(resultados).fetchall()
14
15 for resultado in resultado [:5]:
      print('Id:{} Data:{} Cidade:{}'.format(resultado.Id,
16
      resultado.OrderDate,
        resultado.ShipCity))
17
```



Filtrando dados com where (1)

```
1 import pandas as pd
2 from sqlalchemy import create_engine, Table, MetaData, select
  engine = create_engine('sqlite:///Northwind.sqlite')
5 conn = engine.connect()
  metadata = MetaData()
8 pedidos = Table('Orders', metadata, autoload=True,
    autoload_with=engine)
#print(repr(pedidos))
12 comando = select([pedidos])
13 comando = comando.where(pedidos.columns.Freight < 5)</pre>
14
15 resultados = conn.execute(comando).fetchall()
16
  df = pd.DataFrame(resultados)
18 df.columns = resultados[0].keys()
19 print (df.head())
```



Filtrando dados com where (2)

20	#		Id	CustomerId	EmployeeId	OrderDate	
21	#	0	10259	CENTC	4	2012-07-18	
22	#	1	10261	QUEDE	4	2012-07-19	
23	#	2	10264	FOLKO	6	2012-07-24	
24	#	3	10269	WHITC	5	2012-07-31	
25	#	4	10271	SPLIR	6	2012-08-01	